

卒 業 研 究

論 文 名	マルチモーダル RAG を用いた動機づけ面接対話システム
指導教授	中 野 有 紀 子
提 出 日	令和 8 年 1 月 29 日
学籍番号	S225026
氏 名	工 藤 和 真

成蹊大学 理工学部 理工学科 コンピュータ科学専攻

目次

1	はじめに	3
1.1	研究の背景.....	3
1.1.1	動機づけ面接とは	3
1.2	研究の目的.....	3
1.3	本研究のアプローチ	3
2	関連研究	3
2.1	RAG に関する研究.....	5
2.2	表情特徴量抽出と OpenFace の利用	5
3	データ	5
3.1	対話コーパス	5
3.2	データベースの改良.....	6
4	マルチモーダル RAG を用いた動機づけ面接対話システムの作成.....	7
4.1	システム概要	7
4.2	言語 RAG の実装	8
4.3	マルチモーダル RAG への拡張方針	9
4.3.1	ベクトル結合型アプローチ	9
4.3.2	注釈追加型アプローチ	9
4.3.3	分離検索型アプローチ	11
4.4	各手法の実装	12
4.4.1	表情ベクトル取得と処理.....	12
4.4.2	文章ベクトルとの統合	12
4.4.3	プロンプト設計.....	13
5	実験の評価.....	14
5.1	評価方法	14
5.2	評価結果	16
5.3	考察	18
6	まとめと今後の課題.....	18
6.1	まとめ.....	18
6.2	今後の課題.....	18
7	参考文献	19
8	付録	19

1 はじめに

1.1 研究の背景

動機づけ面接（MI）は、クライアントの内面の動機を引き出すことで行動変容を促すカウンセリング手法として注目されている。MI の効果的实施には、クライアントの語りの内容のみならず、感情、困惑、拒否、あるいは動機の芽生えといった非言語的手がかりを読み取り、応答に反映させることが不可欠である。

一方、大規模言語モデル（LLM）の発展に伴い、外部知識を検索して応答生成に統合する Retrieval-Augmented Generation（RAG）が注目されている。RAG は対話の文脈に関連する知識を外部データから検索し、その検索結果を基に応答を生成することで、より多様で文脈に整合した応答を得られる手法であり、情報検索と生成モデルの統合という点で活発に研究が進んでいる。しかし現在の RAG は主にテキスト情報を対象としており、表情、声のトーン、視線などの非言語情報を検索および応答生成に統合する研究はあまり行われていない。MI のように非言語的状态が対話の質に強く影響する領域では、テキストのみを入力とする対話モデルでは、クライアントの感情変化や状態を適切に理解し、それに応じたカウンセラーらしい応答を生成することが困難である。この点は従来手法が抱える大きな限界である。

1.1.1 動機づけ面接とは

日常生活の中で、「体に悪いものばかりとってしまう習慣をやめられない」、「喫煙は体に 害だ、と頭でわかっていてもついつい吸ってしまう」といった、生活習慣や日常的な行動を 変えるのが難しいと感ずることがある。動機づけ面接とは、このような動機づけ課題を抱えているクライアントに対して行動変容 を促進するためのカウンセリング手法であり、主に心理学や医療分野などで用いられている。動機づけ面接においては、カウンセラー側からの意見の強制や、クライアントの意見への追従は適切なカウンセラーではない。カウンセラーはクライアントの話に理解を示し、変化に対する意欲や動機を「引き出させる」ことが重要である。

1.2 研究の目的

本研究では、従来の RAG にマルチモーダルな入力情報を追加することで、テキストだけでは読み取れない「感情」や「状態」を補足し、カウンセラーらしい適切な対話応答を可能にする MI 対話システムの開発を目的とする。

1.3 本研究のアプローチ

本研究では、従来の言語 RAG を実装したのちに、OpenAI の text embedding-3-small

によるテキストベクトルと OpenFace を使った表情データを含むマルチモーダル情報を RAG へ統合するために、以下の三つのアプローチに取り組んだ。

アプローチ 1：ベクトル結合型アプローチ

文章ベクトルと表情ベクトルを結合し、単一の検索ベクトルとして扱う手法である。テキストと非言語情報を対等に扱うことで、類似例検索段階からマルチモーダルな類似度計算を行う。

アプローチ 2：分離検索型アプローチ

文章ベクトルと表情ベクトルを別々に検索し、それぞれ類似例を抽出する。

アプローチ 3：注釈追加型アプローチ

表情ベクトルを表情を表現するテキストの注釈に変換し、テキスト情報に付与することで RAG に統合する。本手法は、人間のカウンセラーが非言語情報を言語化して理解する過程を模倣することを意図している。

本研究では、上記 3 つの手法を比較し、非言語情報の利用方法が MI 対話モデルに与える効果を検証することで、マルチモーダル RAG の有効性を明らかにする。以下の図 1 は従来の RAG と作成する RAG の流れを示す。この図は、従来の RAG と今回作成するマルチモーダル RAG の仕組みの概要である。




図1 従来の RAG と作成する RAG の流れ

2 関連研究

2.1 RAG に関する研究

Retrieval-Augmented Generation (RAG) は、外部知識を検索し、その検索結果を生成モデルに入力することで、事実性や文脈適合性の高い応答を生成する手法である [1]。RAG は質問応答、対話システム、知識集約型タスクなど幅広い分野で応用されており、LLM のハルシネーションを抑制する手法としても注目されている。従来の RAG に関する研究では、検索対象および検索条件は主にテキスト情報に限定されている。検索時の埋め込み表現としても、文章埋め込みや単語埋め込みが用いられることが一般的である。そのため、RAG は知識検索には有効である一方、話者の感情や状態といった非言語情報を十分に反映することは難しい。

2.2 表情特徴量抽出と OpenFace の利用

顔表情に基づく感情認識は、ヒューマンコンピュータインタラクションや対話システムの分野において重要な研究課題の一つである。多くの研究では、Facial Action Coding System (FACS) に基づく Action Unit (AU) を用いて、表情を客観的な特徴量として表現している。AU は顔筋の動きを単位とした表情記述手法であり、感情推定や対話状態の分析など、幅広い応用が報告されている。OpenFace は、AU の出現や強度を自動推定可能なオープンソースの表情解析ツールであり、表情認識や感情分析を目的とした多くの先行研究で利用されてきた。例えば、AU の強度値を連続値特徴量として機械学習モデルに入力する手法や、AU の組み合わせに基づいて感情状態を推定する手法などが提案されている。また、一部の研究では、AU の強度値に対して閾値を設定し、出現・非出現を二値化することで表情特徴を扱う手法も用いられている [2]。一方で、これらの研究の多くは、感情認識や行動分析そのものを目的としており、生成型対話システム、特に Retrieval-Augmented Generation (RAG) と表情情報を統合した事例は十分に検討されていない。とりわけ、表情特徴をどのように検索・生成過程に組み込み、応答生成に反映させるかについては、未だ体系的な研究が少ないのが現状である。本研究は、この点に着目し、OpenFace により抽出した表情情報を RAG 型対話システムに組み込む手法を検討するものである。

3 データ

3.1 対話コーパス

本研究では、動機づけ面接コーパス [3] に含まれる日本語の書き起こしデータを使用した。本コーパスは、動機づけ面接を用いたカウンセリング対話を収録したものであり、過去の研究においては、食生活に関する動機づけ課題を対象としたドメインのコーパスが用いられている。ここでドメインとは、コーパスが属する特定の分野を指す。本コーパスは、食事や食生活に関する行動変容の課題を抱えるクライアントを対象とし

て、日本語で実施されたカウンセリング対話を収録している。各対話は、カウンセラーとクライアントの発話のやり取りから構成されており、動機づけ面接に特有の共感的応答や問いかけが含まれている。以下の表1にコーパスの例を示す。

表1 コーパスの例

Counselor	今日はどういうことをご相談で来られたんでしょうか
Client	なんか塩分を取り過ぎちゃうことを気にしてます
Counselor	塩分を
Counselor	とりすぎてしまう
Client	つついストレス溜まってる
Counselor	うん

3.2 データベースの改良

本研究では、動機づけ面接対話を対象としたデータベースを構築するため、元の書き起こしデータに対して前処理および情報拡張を行った。

まずは、書き起こしデータの前処理とエンベディング表現の抽出を行った。動機づけ面接コーパスに含まれる書き起こしデータには、「はい」「うん」といった相槌のみから成る発話が含まれている。これらの発話是对話の自然さを保つ役割を果たす一方で、意味的情報が少なく、検索および応答生成においてノイズとなる可能性がある。そこで本研究では、相槌のみから成る発話を削除し、クライアントとカウンセラーの発言が交互に現れるターン系列を作成した。具体例を以下に示す。

処理前（元の書き起こしデータ）

クライアント：最近、運動しなきゃと思っはいるんですけど……

カウンセラー：うん

クライアント：なかなか続かなくて

カウンセラー：はい、それは大変ですね

前処理後（ターン系列化後）

クライアント：最近、運動しなきゃと思っはいるんですけど……なかなか続くて

カウンセラー：それは大変ですね

この処理により、意味的にまとまりのある分析単位を維持しつつ、RAGにおける検索

対象として適したデータ構造を得た．前処理後の書き起こしテキストに対しては，OpenAI(text-embedding-small-3)を用いてベクトル化を行った．生成された文章ベクトルは，RAG におけるコサイン類似度検索用データベースとして利用される．

次に表情ベクトルを新しい検索対象としてデータベースに追加した．本研究では，テキスト情報に加えてクライアントの非言語的状態を考慮するため，OpenFace を用いて抽出した表情特徴量をデータベースに追加した．OpenFace は Facial Action Coding System (FACS) に基づく Action Unit (AU) の強度を推定するツールであり，対話中の表情変化を定量的に表現することが可能である．各発話に対応する時間区間において，OpenFace から得られた AU の値を表情ベクトルとして取得し，テキストデータと対応付けた．OpenFace が出力するフレーム番号、顔位置・姿勢パラメータ (p_0-p_33)，検出信頼度等は，表情の意味的特徴を直接表すものではなく，撮影条件や個人差に強く依存する．そのため，本研究では表情筋活動を表す Action Unit に基づく特徴量のみを採用し，これらのメタ情報および幾何情報は特徴量データベースから除外した．これにより，書き起こしテキストだけでは把握が困難な感情的状態や反応を，数値的特徴量として扱うことが可能となる．これらにより作成されたデータベースの例を表 2 に示す．

表 2 改良後のデータベースの例

話者	発話内容	OpenAIベクトル	Openfaceベクトル
Counselor	今日はどういうこと をご相談で来られた んでしょうか	"[- 0.00787256192415 9527,...]"	"[- 0.01452042721211 9102,...]"
Client	なんか塩分を取り過 ぎちゃうことを気に してます	"[0.0529471486806 8695, ...]"	"[0.0185628738254 3087,...]"
Counselor	塩分を、とりすぎて しまう	"[0.0462299957871 4371,...]"	"[- 0.00552001176401 9728,...]"
Client	つついストレス溜 まってる、ちょっと 時間が...	"[0.0216568298637 86697,...]"	"[0.0195817984640 5983,...]"

4 マルチモーダル RAG を用いた動機づけ面接対話システムの作成

4.1 システム概要

本研究で構築した対話システムは，大規模言語モデル(GPT-4o)を基盤とし，動機づけ面接コーパスから検索された類似対話例を参照しながら，カウンセラー応答を生成する RAG 型対話システムである．図 2 に，構築した対話システムの概要を示す．まず，クライアントの入力発話を受け取り，その発話をベクトル化する．次に，事前に構築した動機づけ面接コーパスのベクトルデータベースから，意味的に類似した発話例をコ

サイン類似度で検索する．検索によって得られた類似例とその周辺文脈をプロンプトに組み込み，大規模言語モデルによってカウンセラー応答を生成する．本研究では，この言語 RAG を基盤として，表情情報を含む非言語的情報を統合することで，マルチモーダル RAG へ拡張する．




図2 システム概要

4.2 言語 RAG の実装

マルチモーダル RAG の基盤となる言語 RAG の実装方法について述べる．言語 RAG の構築は，大きく以下の二つを行った．

第一に，埋め込みモデルの選定を行った．RAG において，埋め込みの質は類似例検索の性能を大きく左右する．適切な類似例を取得できなければ，検索結果を参照して生成される応答の質も低下する．そこで本研究では，類似例検索の性能に着目し，複数の埋め込みモデルの比較を行った．具体的には，BERT，SBERT，および OpenAI の text-embedding-3-small の三つのモデルを対象とし，コサイン類似度を用いた検索結果を比較した．評価は，「意味的に近い文を適切に検索できているか」という観点で定行的に行った．その結果，BERT や SBERT では，「体重が増えました」を入力とした場合に，「食べる量が増えた」といった関連はあるが意味的には異なる文が検索される例が多く見られた．一方，OpenAI の埋め込みでは，「体脂肪が増えてきた」など，表現は異なるが意味的に近い文が選択される傾向が確認された．以上の結果から，本研究では類似例検索において最も適切な埋め込みを生成できると判断し，text-embedding-3-small を採用した．以降の実装において，すべてのテキスト埋め込みはこのモデルを用いて生成している．

第二に，回答生成プロンプトの設計を行った．カウンセラー応答を生成するためのプロンプト設計を行った．プロンプトは，大きく三つの要素から構成される．まず，冒頭に動機づけ面接の定義と基本方針を与える．具体的には，MI が共感的かつ協働的な関わりを通じてクライアントの変化への意欲を高める面接法であり，信頼関係の構築，焦

点づけ、動機の引き出し、行動計画の段階を重視すること、ならびに開かれた質問や傾聴を基本技法として用いることを明示する。次に、類似例検索によって取得された対話例と、その前後3ターンを例として与える。これらの例は、動機づけ面接コーパスから抽出された実際の対話に基づくものであり、カウンセラー応答のスタイルや流れをモデルに提示する役割を果たす。最後に、クライアントの入力発話に対して、動機づけ面接のカウンセラーとして応答を生成するよう指示を与える。以上の構成により、MIの方針を踏まえつつ、類似例を参照した応答生成が可能となる。以下の図3は実際に与えるプロンプト例を示す。

①MIの定義 あなたは熟練したカウンセラーとして、食事に関する問題に焦点を当てた動機づけ面接（MI）セッションを行います。目標は、クライアントの問題の解決にむけた具体的なステップを見つけることです。対話の冒頭ではクライアントとの相互信頼、友情、親近感を深める会話をし、それから食事に関する問題について尋ねるようにします。以下にMIの原則を示します。…
②類似例提示(類似発話+前後3ターン) Client: 佐藤をお願いします Counselor: はいじゃあ佐藤さんよろしくお願いします Client: よろしくをお願いします Counselor: はい、そしたら佐藤さんは今日はこういったことでご相談に… Client: そうですね自炊したいなしたいなと思いつつも… Counselor: 外食の頻度を減らして自炊率をアップしたいと Client: そうですね Counselor: もう少し詳しく、聞かせていただくことは可能ですか Client: そうですねできるだけその、栄養をつけるものを食べたいと…
③応答生成 MIの原則に基づき、ユーザ入力に対するカウンセラーの応答を、類似例を参考に出力してください。応答は長くても2文以内としてください。

図3 プロンプトの構成

4.3 マルチモーダル RAG への拡張方針

言語RAGでは、テキスト情報のみに基づいて類似例検索および応答生成を行っている。しかし、動機づけ面接においては、クライアントの感情や状態といった非言語的情報が対話の質に大きく影響する。そこで本研究では、言語 RAG のデータベースに OpenFace により取得した表情ベクトルを追加し、マルチモーダル RAG へ拡張する。マルチモーダル情報の統合方法として、以下の三つのアプローチを提案する。

4.3.1 ベクトル結合型アプローチ

文章ベクトルと表情ベクトルを連結し、一つのベクトルとして類似例検索を行

い、プロンプトに類似例を 1 つ含める手法である。テキスト情報と非言語情報を同一空間で扱うことで、マルチモーダルな類似度計算を可能にする。図 4 にこのアプローチのシステム概要を示す。




図4 ベクトル結合型アプローチの概要

4.3.2 注釈追加型アプローチ

文章ベクトルを用いて類似例検索を行い、生成時のプロンプトに非言語情報を自然言語の注釈として追加する手法である。例えば、「笑顔が見られる（ポジティブ）」「不快や緊張が示唆される」といった注釈を付与することで、表情情報が応答生成に与える影響を分析する。OpenFace による AU の値には明確な閾値基準が存在しないため、先行研究に基づき経験的に設定される場合が多い。本研究では、これらの AU 値を直接利用するのではなく、閾値判定に基づいて表情状態を自然言語の注釈として表現し、生成時プロンプトに付与する注釈追加型アプローチを用いる。閾値判定の例として AU45_r が 0.4 以上の「場合瞬きが多く、ストレスや疲労が示唆される」という非言語情報をプロンプトに追加する。図 5 にこのアプローチの概要を示す。




図5 注釈追加型アプローチの概要

4.3.3 分離検索型アプローチ

テキスト情報と表情情報をそれぞれ独立に用いて類似例検索を行い、両者から得られた類似対話例を統合して応答生成時のプロンプトにそれぞれ含める手法である。具体的には、クライアント発話から得られる文章ベクトルに基づいて言語的に類似した対話例を検索すると同時に、OpenFaceにより抽出した表情特徴量から得られる表情ベクトルを用いて、非言語的に類似した対話例を別途検索する。そして、それぞれの検索結果を個別の文脈情報としてプロンプトに与えることで、言語情報と非言語情報の両方を考慮した応答生成を行う。図6に分離検索型アプローチの概要を示す。




図6 分離検索型アプローチの概要

4.4 各手法の実装

4.4.1 表情ベクトル取得と処理

本研究では、非言語情報として表情情報を扱うため、顔表情解析ツールである OpenFace を用いて表情特徴量を取得した。OpenFace は、顔画像から Action Unit (AU) と呼ばれる表情筋の動きを数値化して出力するツールであり、表情変化を定量的に扱うことが可能である。本研究では、各発話に対応する時間区間から OpenFace により特徴量を抽出し、これを表情ベクトルとして利用した。取得された特徴量は、各次元ごとに分布のばらつきが異なるため、そのままでは後段の類似度計算において特定の AU が過度に影響する可能性がある。そこで、各特徴量に対して Z 正規化を行った。正規化は各特徴量に対して、データ全体の平均および分散を用いて正規化を行った。以上の流れを図 7 に示す。正規化後の表情ベクトルは、テキスト特徴量と同様にデータベースに格納し、検索および統合処理に利用した。これにより、非言語情報を定量的な特徴量として扱うことを可能にした。分離検索型アプローチにてこれらの処理を行った。




図 7 表情ベクトルの取得と処理の流れ

4.4.2 文章ベクトルとの統合

テキスト情報については、OpenAI が提供する文章埋め込みモデル (text-embedding-small-3) を用いて、各発話の書き起こしテキストをベクトルに変換した。この文章ベクトルは、発話内容の意味的特徴を表現するものであり、従来の RAG における検索キーとして利用される。ベクトル結合型アプローチでは、マルチモーダル情報を扱うため、文章ベクトルと OpenFace から得られた表情ベクトルを統合したベクトルを作成した。その概要を図 8 に示す。具体的には、文章ベクトルと正規化済み表情ベクトルを連結（ベクトル結合）することで、単一の特徴ベクトルを構成した。この統合ベクトルを新たにデータベースへ追加し、検索時にはテキス

トのみの場合と、テキスト+表情情報を含む場合の両方を比較可能とした。これにより、発話内容だけでなく、発話時の非言語的状态を考慮した類似例検索が可能となる。




図8 文章ベクトルと表情ベクトルの結合

4.4.3 プロンプト設計

本節では、注釈追加型におけるプロンプト設計について述べる。注釈追加型では、OpenFace から得られる AU 強度値に対してあらかじめ閾値を設定し、その値を超えた場合にのみ非言語情報をテキスト形式でプロンプトへ付加した。閾値の設定にあたっては、ChatGPT を用いて他研究における AU 強度の扱い方を調査し、先行研究で一般的に用いられている基準を参考に決定した。具体的には、特定の AU が閾値を超えた場合に、「笑顔が見られる」「緊張した表情が見られる」などの簡潔な自然言語表現に変換し、RAG における類似例提示部分へ追加した。この処理により、LLM が非言語的文脈を明示的に認識した状態で応答生成を行えるようにした。一方、閾値を超えない場合には非言語情報を「顕著な表情特徴は見られない」と付与し、テキスト情報のみを用いた従来型のプロンプト構成に近い形とした。これにより、不必要な情報付与を避けつつ、表情変化が顕著な場面のみ非言語情報を活用する設計とした。以上の流れを図9に示す。

①MIの定義 あなたは熟練したカウンセラーとして、食事に関する問題に焦点を当てた動機づけ面接（MI）セッションを行います。目標は、クライアントの問題の解決にむけた具体的なステップを見つけることです。対話の冒頭ではクライアントとの相互信頼、友情、親近感を深める会話をし、それから食事に関する問題について尋ねるようにします。以下にMIの原則を示します。…
②類似例提示(類似発話+前後3ターン)+非言語情報 Client: 佐藤をお願いします Counselor: はいじゃあ佐藤さんよろしくをお願いします Client: よろしくをお願いします Counselor: はい、そしたら佐藤さんは今日はどういったことでご相談に… Client: そうですね自炊したいなしたいなと思いつつも… Counselor: 外食の頻度を減らして自炊率をアップしたいと Client: そうですね Counselor: もう少し詳しく、聞かせていただくことは可能ですか Client: そうですねできるだけその、栄養をつけるものを食べたいと… 以下は今回のクライアントの表情（非言語情報）です： 【非言語情報】{openface_expression}
③応答生成 ユーザ入力(例：自炊をしたいと思っています) MIの原則に基づき、ユーザ入力に対するこの非言語情報も踏まえて、クライアントの感情に寄り添ったカウンセラーの応答を、類似例を参考に出力してください。応答は長くても2文以内としてください。

図9 プロンプト設計

5 実験の評価

5.1 評価方法

本章では、本研究で提案するマルチモーダル RAG を用いた動機づけ面接対話システムの有効性を検証するための評価方法について述べる。本研究では、非言語情報の導入方法の違いがカウンセラー応答の品質に与える影響を比較することを目的とし、以下の4手法を比較対象とする。第一に言語 RAG、第二にベクトル結合型 RAG、第三に注釈追加型 RAG、第四に分離検索型 RAG である。

本研究では、生成されたカウンセラー応答の品質を評価するため、順位付け方式を採用する。各質問に対して4手法それぞれから生成された4つの応答を1組とし、評価者はこれらを相互に比較した上で、最も良いと判断した応答から順に1位から4位までの順位を付与する。なお、同順位は認めず、必ずすべての応答に異なる順位を付けるものとする。評価は以下の4つの観点に基づいて総合的に行う。

- ① MI としてふさわしい応答であるか。動機づけ面接の基本的な考え方や原則に沿った応答となっているか、すなわち、クライアントの自己決定を尊重し、変化への動機づけを促す姿勢が示されているかを評価する。
- ② 表情情報に沿った応答であるか。クライアントの表情が示す感情状態を踏まえ、カ

ウンセラーの応答のトーンや内容が適切に一致しているかを評価する。

- ③ カウンセラーらしい応答であるか。クライアントの感情や状況を理解しようとする姿勢が表れているか、また、相談場面に適した言葉遣いや応答構造となっているかを評価する。
- ④ 応答が適切かつ妥当であるか
クライアントの発話内容や対話全体の文脈に即した応答となっており、不自然さや逸脱がないかを評価する。

これら 4 つの観点を個別に点数化するのではなく、評価者は総合的な観点から応答の優劣を判断し、各応答に順位を付与する。

次に評価用データの作成について述べる。評価用データとして、あらかじめ用意した 10 個の質問文を用い、各モデルに対して同一の質問を入力することでカウンセラー応答を生成した。これにより、各モデルにつき 10 個、合計 40 個（10 問×4 モデル）の質問—応答ペアを作成した。評価者には、各質問文とそれに対応する 4 つのカウンセラー応答のみを提示し、それぞれの応答がどの手法によって生成されたものであるかは伏せた状態で評価を行った。これにより、モデルに関する先入観の影響を排除し、応答内容そのものに基づいた評価が行われるよう配慮した。図 10 に評価実験の例を示す。

Q1

★

クライアント：最近塩分をとりすぎてしまいます

カウンセラー①：塩分を取りすぎてしまうことに気づいていらっしゃるのですね。ストレスが原因であることも考えられるようですが、他にどのような状況で塩分を取りすぎると感じますか？

カウンセラー②：それはストレスを感じたときに手が伸びてしまうのですね。どのような状況で特にストレスを感じる人が多いですか？

カウンセラー③：塩分を取り過ぎてしまうことについてお話ししてくださってありがとうございます。どんな状況で塩分を多く取ってしまうことが多いと感じていますか？

カウンセラー④：そのお気持ちよくわかります。具体的にどのような状況や気持ちの時に塩分ををとりたくなるのかももう少し聞かせてください。



※上記の写真はクライアントの表情です。

	カウンセラー①	カウンセラー②	カウンセラー③	カウンセラー④
1位	☐	☐	☐	☐
2位	☐	☐	☐	☐
3位	☐	☐	☐	☐
4位	☐	☐	☐	☐

図 10 評価実験の例

5.2 評価結果

本節では、順位付け方式によって得られた評価結果について述べる。全サンプルにおける平均スコアを各モデルのスコアを1位を4点、2位を3点、3位を2点、4位を1点として算出した。図 11 に概要を示す。結果として分離検索型 RAG が最も高い評価

が得られ、次点で注釈追加型 RAG、次に言語 RAG、一番低い評価としてベクトル結合型 RAG となった。




図 11 評価結果

次に分散分析によるモデル間比較として分散分析、多重比較を行った。表 3 に比較結果を示す。各モデルの違いが平均スコアを変動させる要因として統計的に有意であるかを検証するため、一元配置分散分析 (One-way ANOVA) を行った。その結果、 $F = 14.87$, $p < 0.001$ となり、モデルの要因が有意であることが確認された。次に、どのモデル間に有意差が存在するかを明らかにするため、Tukey の HSD 法による多重比較を行った。まず、言語 RAG と注釈追加型 RAG、および言語 RAG とベクトル結合型 RAG の間には有意差は認められなかった。一方で、言語 RAG と分離検索型 RAG の間には有意差が認められ、分離検索型 RAG の方が有意に高い評価を得たことが分かった ($p < 0.001$)。また、注釈追加型 RAG とベクトル結合型 RAG の間にも有意差が認められ、ベクトル結合型 RAG が注釈追加型 RAG よりも高い評価を得る結果となった ($p < 0.01$)。さらに、注釈追加型 RAG と分離検索型 RAG、およびベクトル結合型 RAG と分離検索型 RAG の間にも有意差が認められ、いずれも分離検索型 RAG が最も高い評価を示した。検定には、Bonferroni 補正を適用している。これらの結果から、分離検索型 RAG と他の多くの手法との間で有意差が存在することが示された。

表 3 比較結果

比較ペア	平均順位との差	P値	判定
分離検索 vs 結合	0.75	0.0000	有意差あり
分離検索 vs 言語	0.52	0.0000	有意差あり
分離検索 vs 注釈追加	0.37	0.0155	有意差あり
注釈追加 vs 結合	0.38	0.0118	有意差あり
言語 vs 結合	0.23	0.2102	有意差なし
言語 vs 注釈追加	0.15	1.0000	有意差なし

5.3 考察

分離検索型 RAG は、全モデル中で最も平均順位が高く、他モデルとの差も統計的に有意であった。しかしながら、この結果は分離検索という構造自体が必ずしも不適切であることを示すものではなく、few-shot プロンプトに与えられる具体例の構成が評価に影響を与えた可能性が考えられる。本研究の分離検索型 RAG では、言語情報と表情情報を別々に類似検索した結果として、2つの類似例を few-shot として提示している。このように複数の具体例を与えることは、モデルにとって判断材料が増えるという利点がある。

また、注釈追加型 RAG は、表情情報をテキスト注釈として付加する手法では、LLM が解釈しやすい形で渡すことが評価が高くなった要因だと考える。一方、非言語情報が補助的な役割に留まり、応答生成に十分に活用されなかった可能性を示唆している。

また、評価が一番低かったベクトル結合型 RAG については、単に非言語情報を導入するだけでは必ずしも応答品質が向上しないことを示している。ベクトル結合型 RAG が低い評価となった要因として、言語情報と表情情報を単一のベクトル空間に結合することで、両者の意味的特性が相互に干渉し、検索結果の適切性が低下した可能性が考えられる。特に、言語情報と表情情報は意味構造や分布特性が異なるため、連結による統合は、MI 文脈において重要な言語的ニュアンスや感情的手がかりを十分に保持できなかった可能性がある。

6 まとめと今後の課題

6.1 まとめ

本研究では、動機づけ面接におけるカウンセラー応答の質向上を目的として、言語情報と非言語情報を統合したマルチモーダル RAG 型対話システムの構築および評価を行った。特に、非言語情報の扱い方の違いが、応答の評価に与える影響について検証することを目的とした。結果として、分離検索型 RAG が最も高い評価を得た。言語情報と非言語情報を統合したマルチモーダル RAG が有効であることを示すとともに、非言

語情報の扱い方の違いが応答評価に与える影響を明らかにした。

6.2 今後の課題

今後の課題としては、分離検索型 RAG における具体例数を統一した条件での比較実験や、言語と表情の対応関係を考慮した類似例選択手法の検討が挙げられる。また、表情情報以外の非言語情報（視線や音声特徴など）を統合したマルチモーダル RAG の拡張が考えられる。また、異なる特徴量のベクトルの結合方法について検討していく必要がある。

7 参考文献

[1] Patrick Lewis, Ethan Perez, Aleksandra Piktus, Fabio Petroni, Vladimir Karpukhin, Naman Goyal, Heinrich Küttler, Mike Lewis, Wen-tau Yih, Tim Rocktäschel, Sebastian Riedel. Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks, 2020

[2] Koh Shimokawa.

Assessing Automated Facial Action Unit Detection Systems for Analyzing Cross-Domain Facial Expression Databases, 2021, Sensors, 21(12), 4222

<https://www.mdpi.com/1424-8220/21/12/4222>

[3] Yukiko I. Nakano, Eri Hirose, Tatsuya Sakato, Shogo Okada, Jean-Claude Martin: Detecting Change Talk in Motivational Interviewing using Verbal and Facial Information, ICM2022, p. 5–14.

8 付録

注釈追加型アプローチにおける言語化の条件として用いる AU の値の扱い方については、表 5 に示す。

表 5 AU による言語化の条件

$AU12_r > 0.85$ and $AU06_r > 0.8$	笑顔が見られる（ポジティブ）
$AU04_r > 0.3$ and $AU01_r > 0.25$	眉の緊張が見られ、不安や心配の感情が示唆される
$AU15_r > 0.1$	口角が下がり、落ち込みが示唆される
$AU45_r > 0.4$	瞬きが多く、ストレスや疲労が示唆される
$AU07_r > 0.7$ and $AU04_r > 0.7$	不快や緊張が示唆される
$gaze_angle_x > 0.3$ or $gaze_angle_y > 0.3$	視線が大きく逸れており、不安や集中困難がある可能性
else	顕著な表情特徴は見られない